

# Tool Wear Prediction With Convolutional Neural Networks

使用残差剩余卷积网络预测刀具磨损

Dali Cao, Kido Zhang

西北工业大学机电学院

September 3, 2017

# 目录

- ① 概述
- ② 实验方法
- ③ 深度学习实验以及结果



# 刀具的磨损量检测

## 概念

通过一系列的传感器技术得到信号，进而以此预测刀具的磨损量

## 重要性

约有 7-20% 的机器的宕机原因都是刀具的磨损，这也是生产力下降的一个非常重要的原因 [Kegg, 1984, Kurada and Bradley, 1997]

## 难题


刀具磨损量的检测仍然有很多基于 Taylor [Marksberry and Jawahir, 2008] 刀具寿命等式的模型以供参考，然而其并没有考虑加工中的不稳定性。

# 当今手段

如今大量的人工智能算法都广泛的处理来自测力计，加速度计，声发射和电流功率传感器的数据 [Cho et al., 1999]

步骤有：

- ① 进行加工实验
- ② 通过传感器得到信号
- ③ 信号的预处理（放大或者滤波）
- ④ 特征提取
- ⑤ 使用算法生成模型并且训练数据
- ⑥ 预测结果



# 卷积神经网络

## 为什么使用卷积神经网络？

- 因为输入数据具有局部相关性
- 输入数据在局部特征也具有平移不变性，也就是说在不同位置都具有共性的局部特征，这样在多层堆叠下，底层局部特征可以抽取成高层全局特征。
- 权值共享则可以大大降低网络的训练难度

## 为什么需要使用残差结构来构造神经网络

- 能有效的解决梯度消失的问题
- 能够搭建更深的神经网络，使得神经网络的表达能力更强

# 信号来源和其预处理

## 数据来源

所有的加工数据来自于 PHM 学会 2010 关于刀具磨损量的数据 [2010, ]

## 数据预处理 - 小波变换

对信号进行等数量的时间步长均匀采样，并对每个维度的信号进行小波变换，得到两层高频和一层低频信号，进而拼接作为神经网络的输入

# 神经网络模型

我们使用了残差剩余卷积神经网络来处理模型，其使用 Keras（后端是基于 GPU 的 Tensorflow）框架编写。

- 使用了较深的网络（10-30）来表达这个过程
- 使用平均方差来作为误差函数训练
- 使用 Adam 优化器来训练整个模型



# 机器的设置和处理

## 数据预处理

整个实验运行在工作站上，其使用的是一块 Quadro M2000 显卡。整个实验数据首先经过小波变换后，手动打乱整个数据集，然后按照训练集数据集 0.8:0.2 划分。

## 网络的选择

使用函数式模型搭建整个残差剩余网络，以三个不同的波形作为输入，输出是三齿的磨损量。残差剩余网络的网络深度按照 5,10,20,30 取值。以亚当优化器作为模型的优化器，以平均平方误差作为损失函数，以保证整个问题是一个凸函数的问题。

## 过程监控

使用 TensorBoard 监控整个训练过程，得到每个训练周期内的损失值。



# 实验过程

采用 Adam 算法，测试不同深度的残差剩余网络，并且在其中选择 loss 最低的结果作为最终的模型。

(开 Tensorboard 手动演示。。。)




# 综述

根据我们的预测结果和实验值结果，在残差神经网络深度为 15 层的时候，其在训练和验证集的效果最佳。同时可以得到如图所示的概率分布曲线。


算法在以 Quadro M2000 的 CUDNN 计算环境下，预测 945 个小切削过程的刀具磨损计算时间在 0.2-0.3 秒内。




# 实验结果






# 实验结果



# 实验结果



# 误差频率分布



# 结论

- ❶ 残差剩余网络能够有效的预测刀具的磨损量（翻阅论文发现其也比基于阈值的方法更加稳健）
- ❷ 计算开销在基于 CUDNN 的计算环境下很小



# Reference



2010, P.

2010 phm society conference data challenge.

<https://www.phmsociety.org/competition/phm/10>.

Accessed Jun 2, 2010.



Cho, D.-W., Lee, S. J., and Chu, C. N. (1999).

The state of machining process monitoring research in korea.

*International Journal of Machine Tools and Manufacture*, 39(11):1697–1715.



Kegg, R. L. (1984).

One-line machine and process diagnostics.

*CIRP Annals-Manufacturing Technology*, 33(2):469–473.



Kurada, S. and Bradley, C. (1997).

A review of machine vision sensors for tool condition monitoring.

*Computers in industry*, 34(1):55–72.



Marksberry, P. and Jawahir, I. (2008).

A comprehensive tool-wear/tool-life performance model in the evaluation of ndm (near dry machining) for

sustainable manufacturing

Dali Cao, Kido Zhang (NWPU)

Tool Wear Prediction With Convolutional Neural Network

September 3, 2017

16 / 16

